STU FEI

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

ÚRK

Hlboké neurónové siete

Prednáška č. 7 – časť 2

Návrh HNS pre Edge zariadenie





28.10.2025 | Ing. Slavomír Kajan, PhD., D-704, slavomir.kajan@stuba.sk, Ing. Jozef Goga

Edge zariadenie

- Motivácia
  - Nízka spotreba energie
  - Malé rozmery
  - Zachovaná dátová integrita
- Jetson AGX Xavier od Nvidie
- Maximálny výpočtový výkon - 10 TFLOPS-ov
  - Maximálna výpočtová náročnosť detektora - 8 TFLOPS-ov
- Možnosť optimalizácie detektora pre zariadenie



Rozpoznávanie ľudskej aktivity - násilia

- Motivácia - neefektívne manuálne rozpoznávanie
- Princíp - nutnosť zachytiť dynamiku, architektúra s pamäťovým efektom
- Adaptivita - nutnosť použitia ML/DL štruktúr





Cheng, M., Cai, K. and Li, M., 2021, January. RWF-2000: an open large scale video database for violence detection. In 2020 25th International Conference on Pattern Recognition (ICPR) (pp. 4183-4190). IEEE.

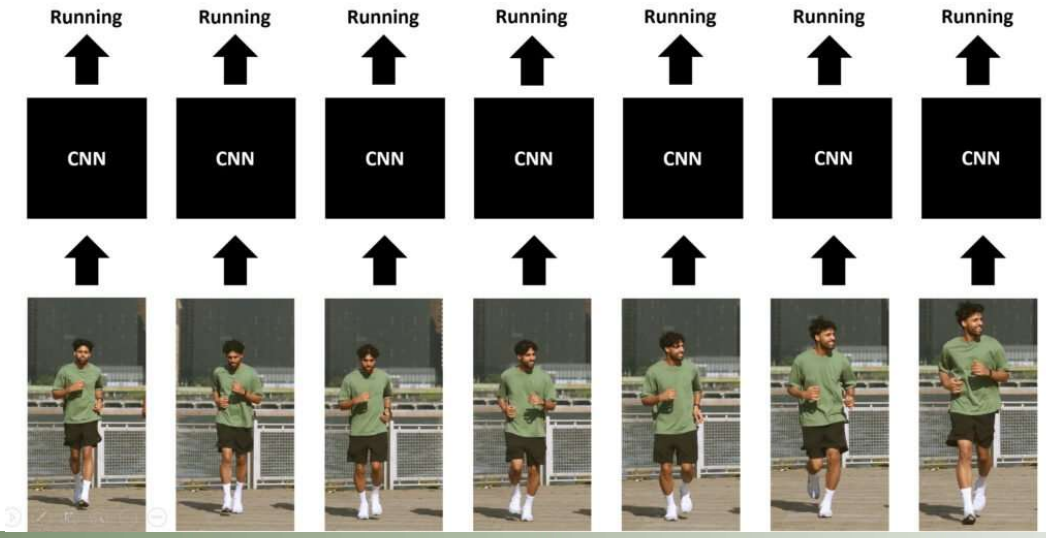
Dataset video sekvencií násilia RWF2000

- 2000 sekvencií
  - 2 kategórie - násilie/nenásilie
- 5 sekúnd dlhé, framerate - 30 snímok za sekundu
- Diverzitný dataset – reflektuje realitu
    - davy, veľký chaos, malé objekty v diaľke, malé rozlíšenie...
- Rozdelenie 80/20 – trénovacia/validačná časť
- Najvyššia dosiahnutá presnosť nad validačnou časťou DS – 89,75%

Cheng, M., Cai, K. and Li, M., 2021, January. RWF-2000: an open large scale video database for violence detection. In 2020 25th International Conference on Pattern Recognition (ICPR) (pp. 4183-4190). IEEE.

Konvolučná sieť + klasifikátor strojového učenia (SVM)

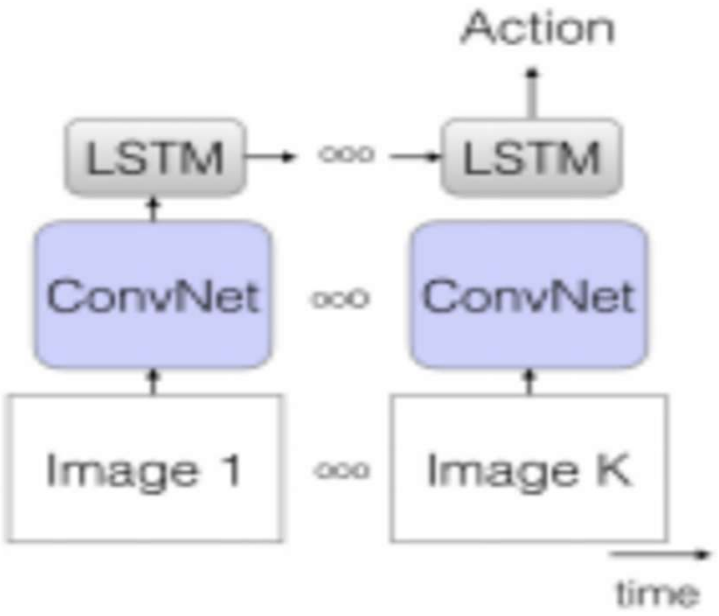
- Konvenčný konv. klasifikátor používaný na každú snímku sekvencie
  - Extrahuje mapy príznakov
- Mapy príznakov sú klasifikované pomocou metód strojového učenia
  - Pamäťový element



Taha Anwar - BleedAI.com. Introduction to Video Classification and Human Activity Recognition, [online] <https://learnopencv.com/introduction-to-videoclassification-and-human-activity-recognition/

Konvolučna sieť + LSTM rekurentná sieť

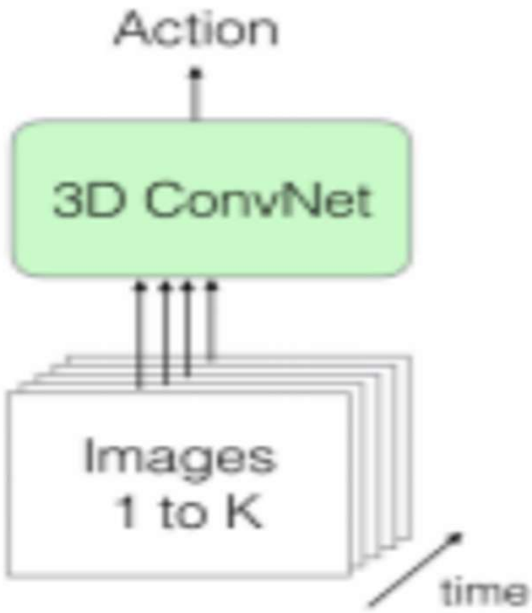
- Použitie konvolučnej siete je rovnaké ako v predošlom prípade
- Mapy príznakov sú klasifikované pomocou LSTM rekurentnej siete
  - Pamäťový element



Bilkhu, M. and Ayyubi, H., 2019. Human Activity Recognition for Edge Devices. arXiv preprint arXiv:1903.07563.

3D konvolučná sieť

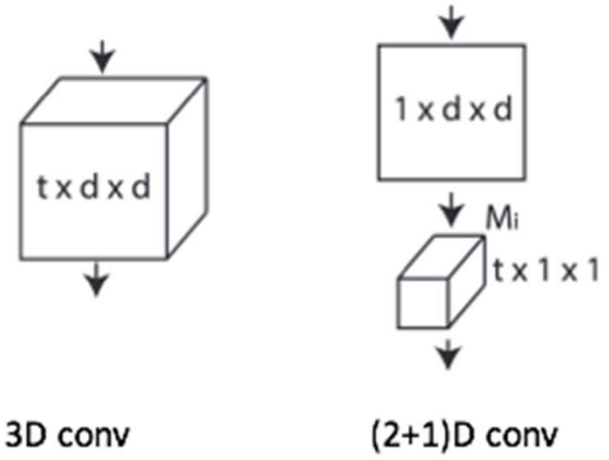
- Na celú sekvenciu sa aplikuje 3-rozmerné konvolučné jadro
- Sieť sa vie natrénovať na všetky závislosti priamo
- Veľká výpočtová náročnosť
  - Veľké množstvo parametrov
  - Samotná sieť v jednom momente spracováva všetky snímky



Bilkhu, M. and Ayyubi, H., 2019. Human Activity Recognition for Edge Devices.
arXiv preprint arXiv:1903.07563.

(2+1)D konvolučná sieť

- Optimalizovaná 3D konvolučná sieť
  - Redukcia parametrov
  - Redukcia výpočtovej náročnosti
- Emulácia 3D konvolúcie rozdelením
  - Priestorová časť – 2D konvolúcia
  - Časová časť – 1D konvolúcia



Bilkhu, M. and Ayyubi, H., 2019. Human Activity Recognition for Edge Devices. arXiv preprint arXiv:1903.07563.

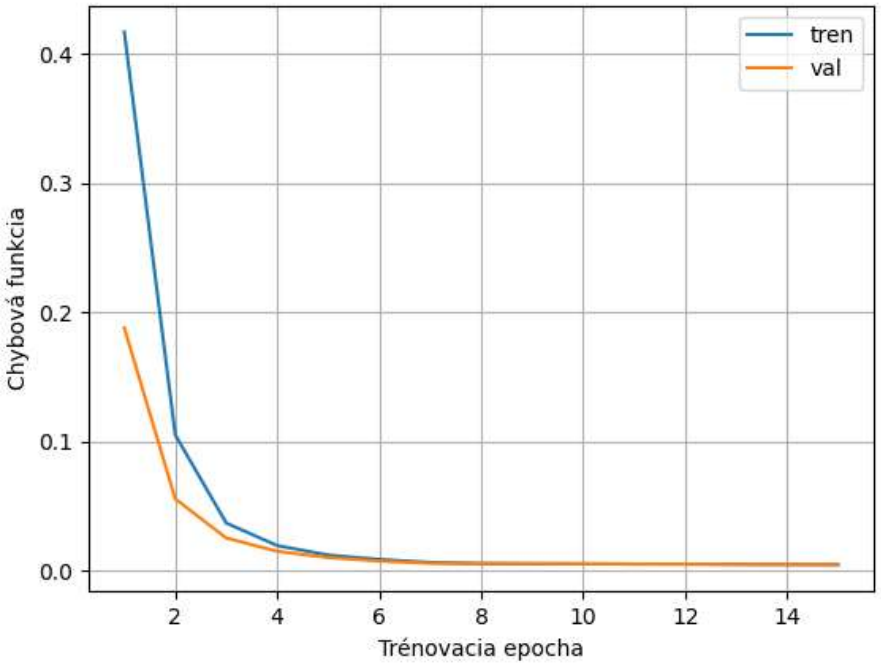
Experimenty so štruktúrami detektora

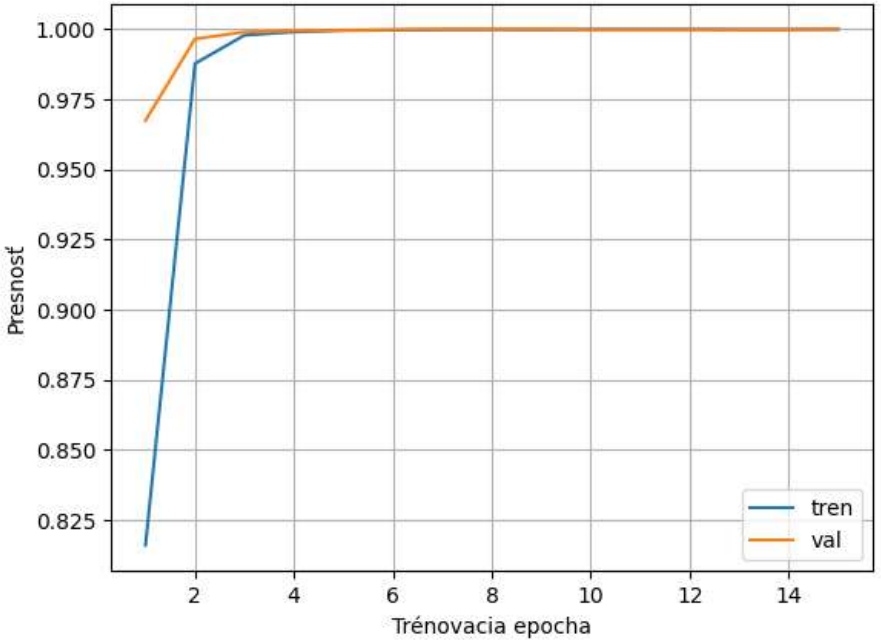
- Úprava datasetu – 30 FPS (1/30s – 0,0333s)
- Framework-y - Pytorch, Scikit-learn, openCV, Pytorch-OpCounter.
- Štruktúra experimentov:
  - Jedna iterácia experimentu – 5x pretrénovanie štruktúry
    - Ladenie parametrov – CNN+SVM, CNN+LSTM (5x pretrénovanie pre každý param.)
    - Štandardne používané parametre – 3D CNN, (2+1)D CNN
- Meranie výpočtovej náročnosti
  - Výpočtová náročnosť - FLOPS
  - Počet parametrov štruktúry
  - Priemerná doba behu detektora z 30 spustení

Dotrénovanie ResNet18 – Extraktor máp príznakov

- “Single-shotový” dataset
  - 45 000 snímok
  - 80/20
- Trénovacie parametre
  - SGD optimizér
  - Krok učenia 0,001
  - Chybová funkcia - krížová entropia
  - Plánovač kroku učenia – po každej 7. epoche sa zníži o rád
  - Veľkosť dávky 600
  - 15 epoch

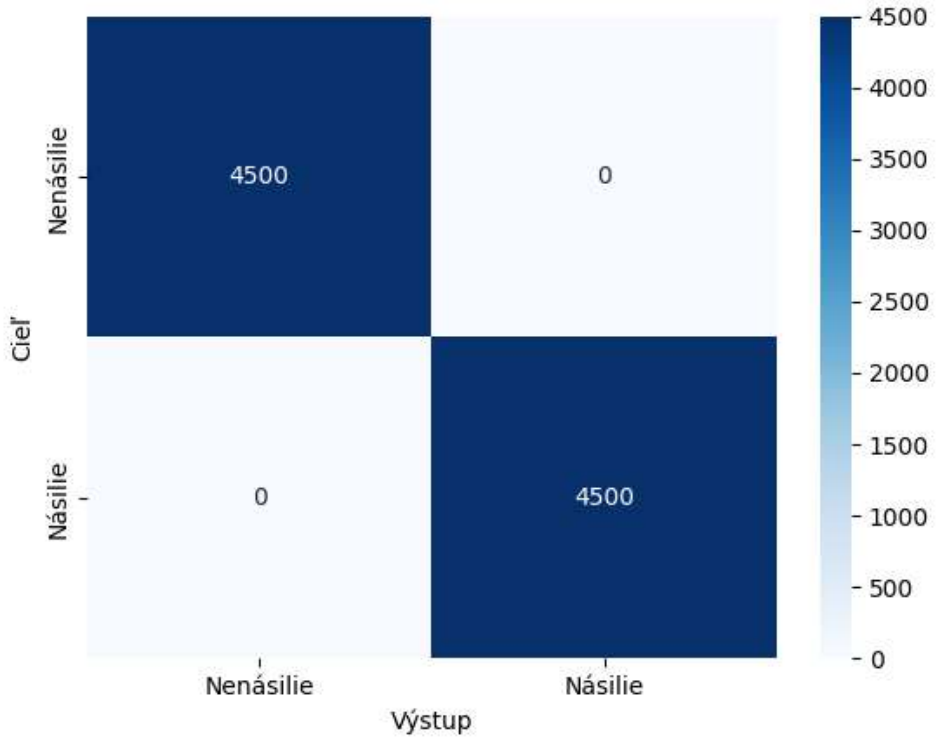
Dotrénovanie ResNet18 – Extraktor máp príznakov



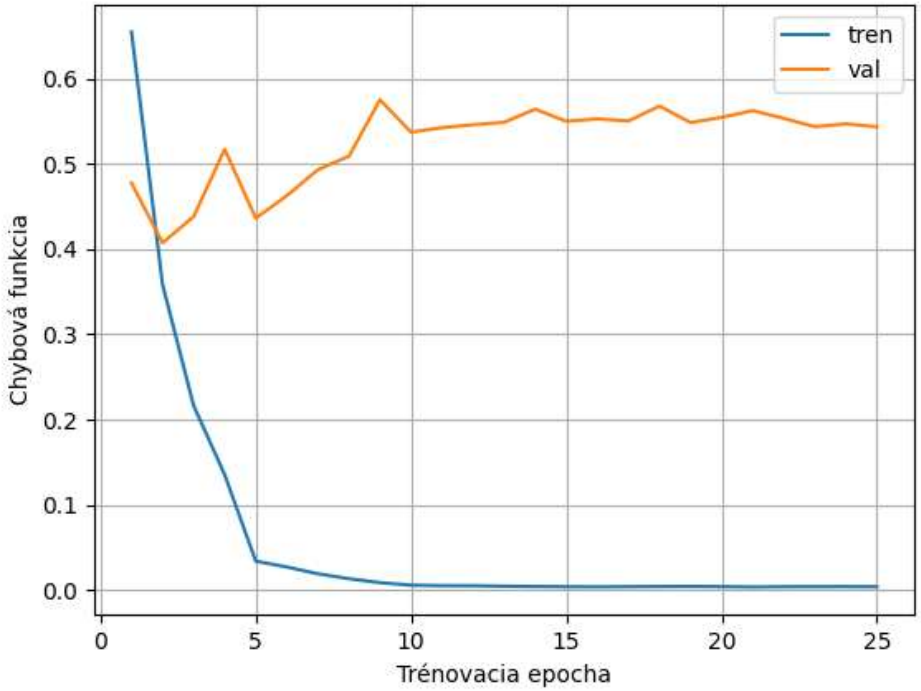


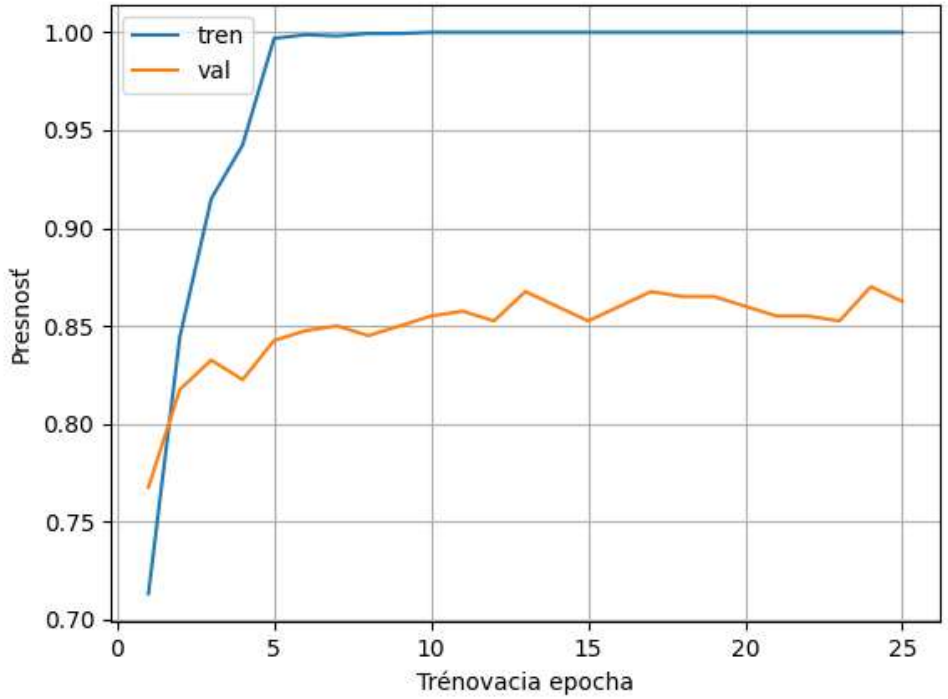
Dotrénovanie ResNet18 – Extraktor máp príznakov

	Validačná presnosť [%]
Experiment 1	100,00
Experiment 2	100,00
Experiment 3	98,96
Experiment 4	100,00
Experiment 5	99,45

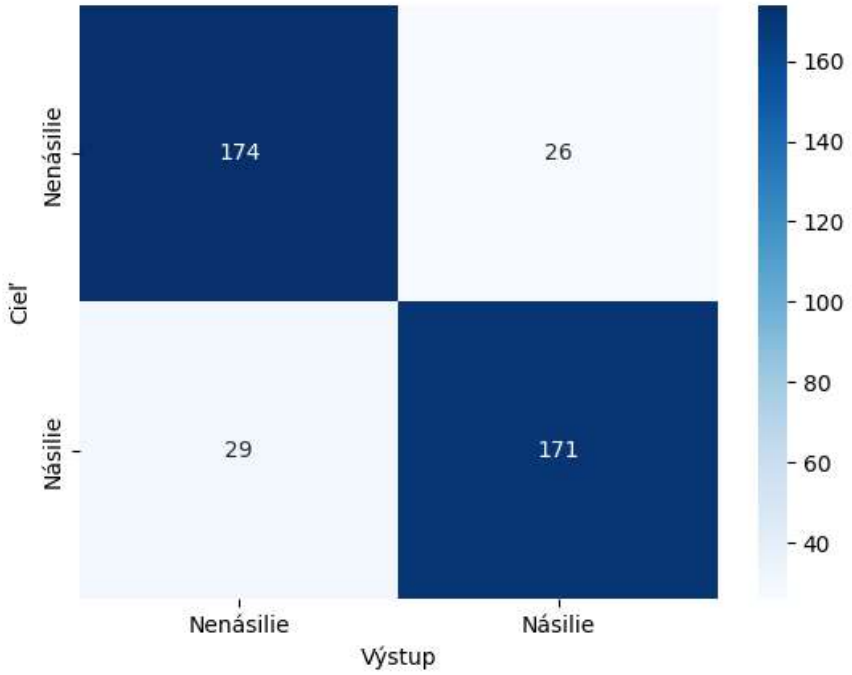


Dotrénovanie siete MoViNet – (2+1)D CNN





Validácia dotrénovanej siete MoViNet - (2+1)D CNN



senzitivita	0,855
špecificita	0,870
precision	0,878
F1 skóre	0,861

Porovnanie štruktúr – úspešnosť metrík

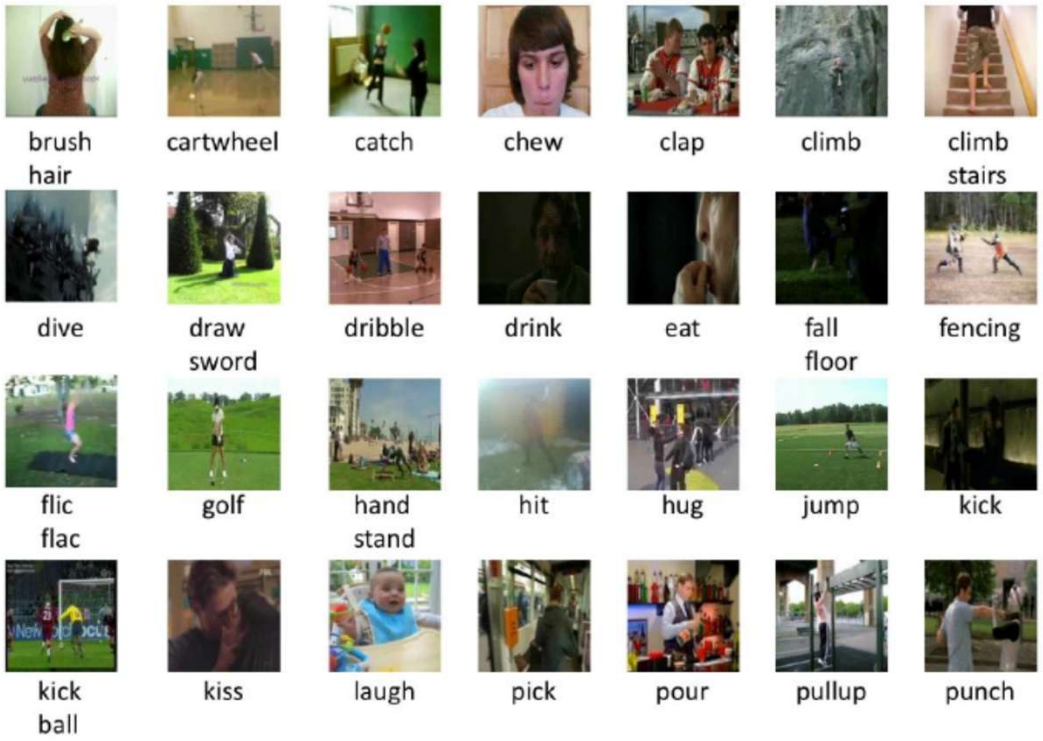
Štruktúra	Priem. val. presnosť [%]	Min. val. presnosť [%]	Max. val. presnosť [%]	Senz.	Špeci.	Prec.	F1 skóre
CNN + SVM	81,00	81,00	81,00	0,795	0,815	0,811	0,803
CNN + LSTM	76,75	75,50	79,50	0,750	0,855	0,838	0,792
3D CNN	66,75	-	-	-	-	-	-
(2D+1D) CNN	85,25	84,00	86,25	0,855	0,870	0,878	0,861

Porovnanie štruktúr – výkonová závislosť

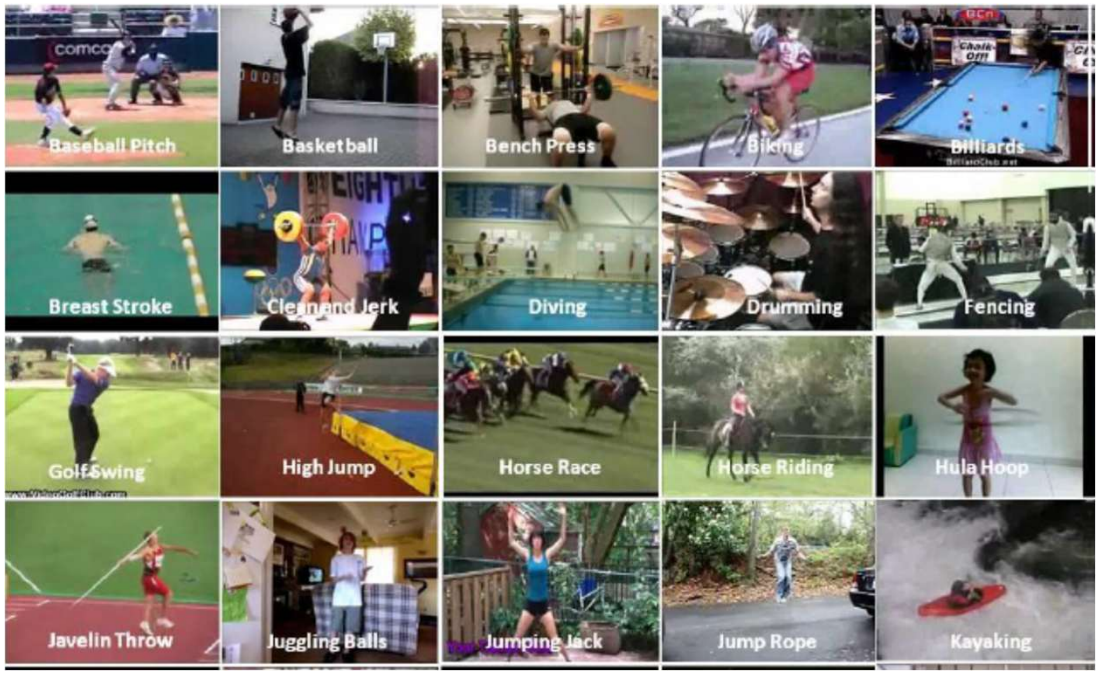
Štruktúra	Výpočtová náročnosť [GFLOPS]	Počet parametrov štruktúry	Priemerný čas behu 30 spustení [s]
CNN + SVM	3,637+	11 176 512+	0,640
CNN + LSTM	4,900	15 380 034	0,026
3D CNN	116,200	33 167 298	-
(2D+1D) CNN	24,177	3 748 016	0,312

Rozpoznávanie ľudskej aktivity – datasety

HMDB51



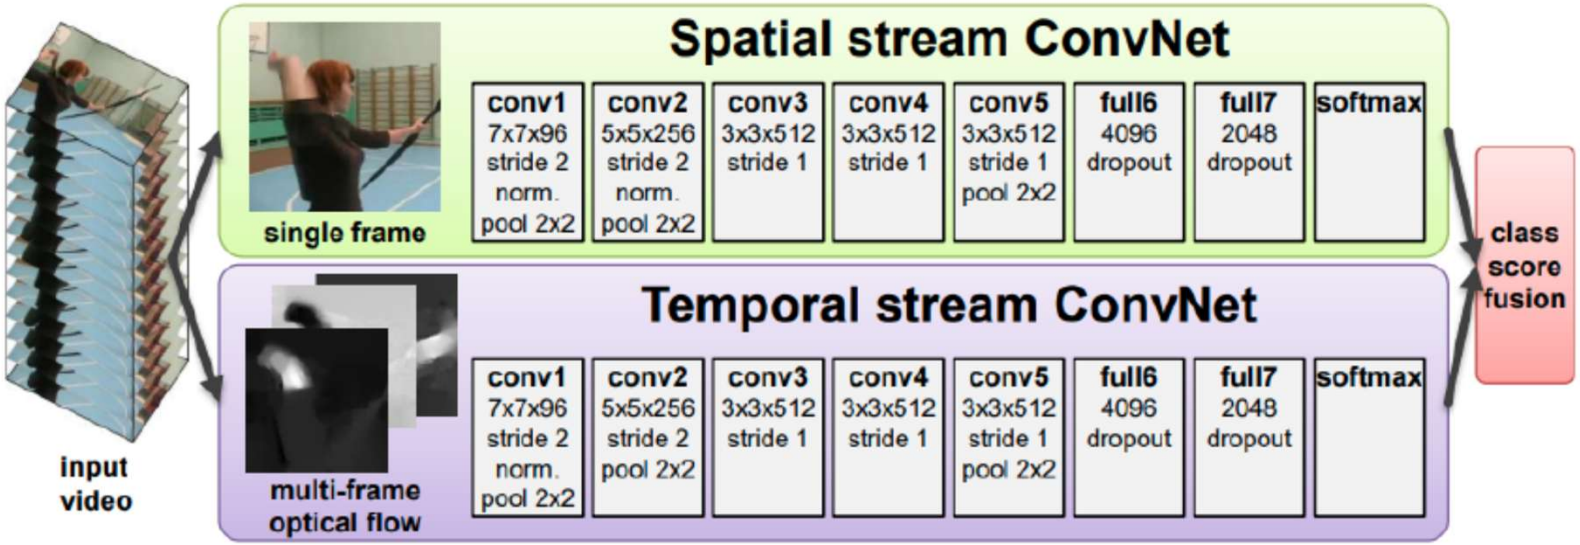
UCF50



H. Kuehne, H. Jhuang, E. Garrote, T. Poggio and T. Serre, "HMDB: A Large Video Database for Human Motion Recognition," in Proceedings of the International Conference on Computer Vision (ICCV), 2011 [cit. 2023-010-20]. Available: https://ieeexplore.ieee.org/document/6126543

UCF-50 [online]. [cit. 2024-02-20]. Available: https://www.crcv.ucf.edu/data/UCF50.php

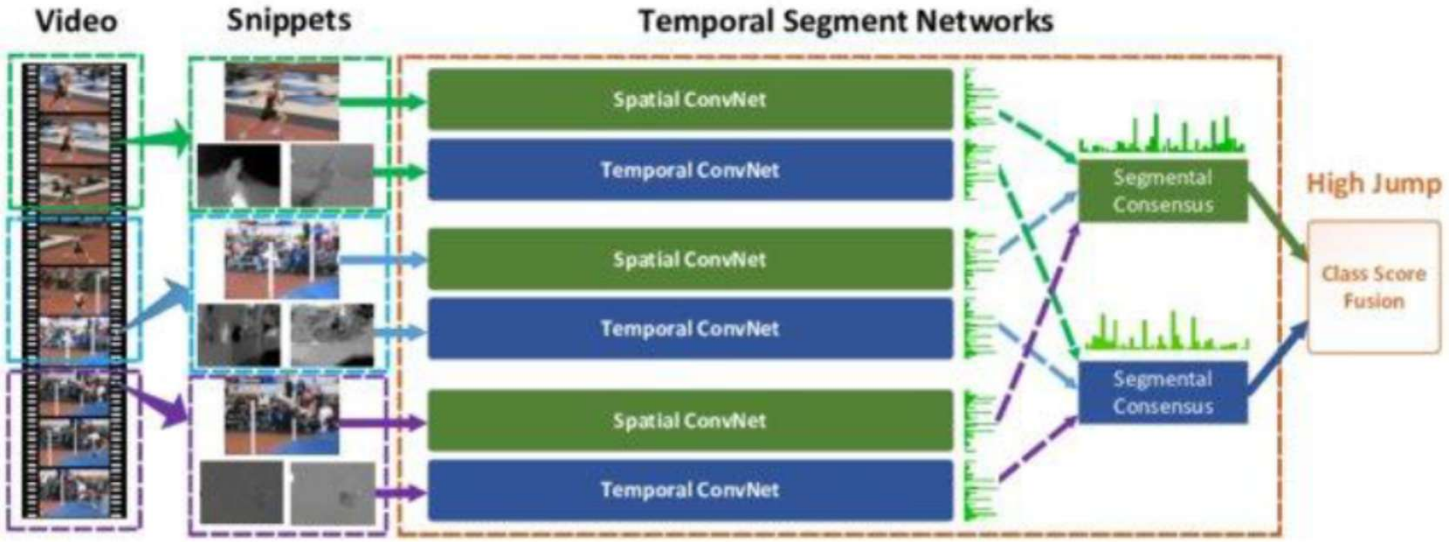
Two-stream CNN



- Spatial stream - Priestorový tok je zodpovedný za spracovanie vzhľadu video snímok a je podobný štandardnému CNN na klasifikáciu obrazu.
- Temporal stream - Časový tok je na druhej strane zodpovedný za spracovanie informácií o pohybe vo videu. Ako vstup berie sekvenciu obrazov optického toku, ktorá predstavuje pohyb pixelov medzi po sebe idúcimi snímkami videa.

K. Simonyan and A. Zisserman, "Two-Stream Convolutional Networks for Action Recognition in Videos," in *Advances in neural information processing systems*, 2014.

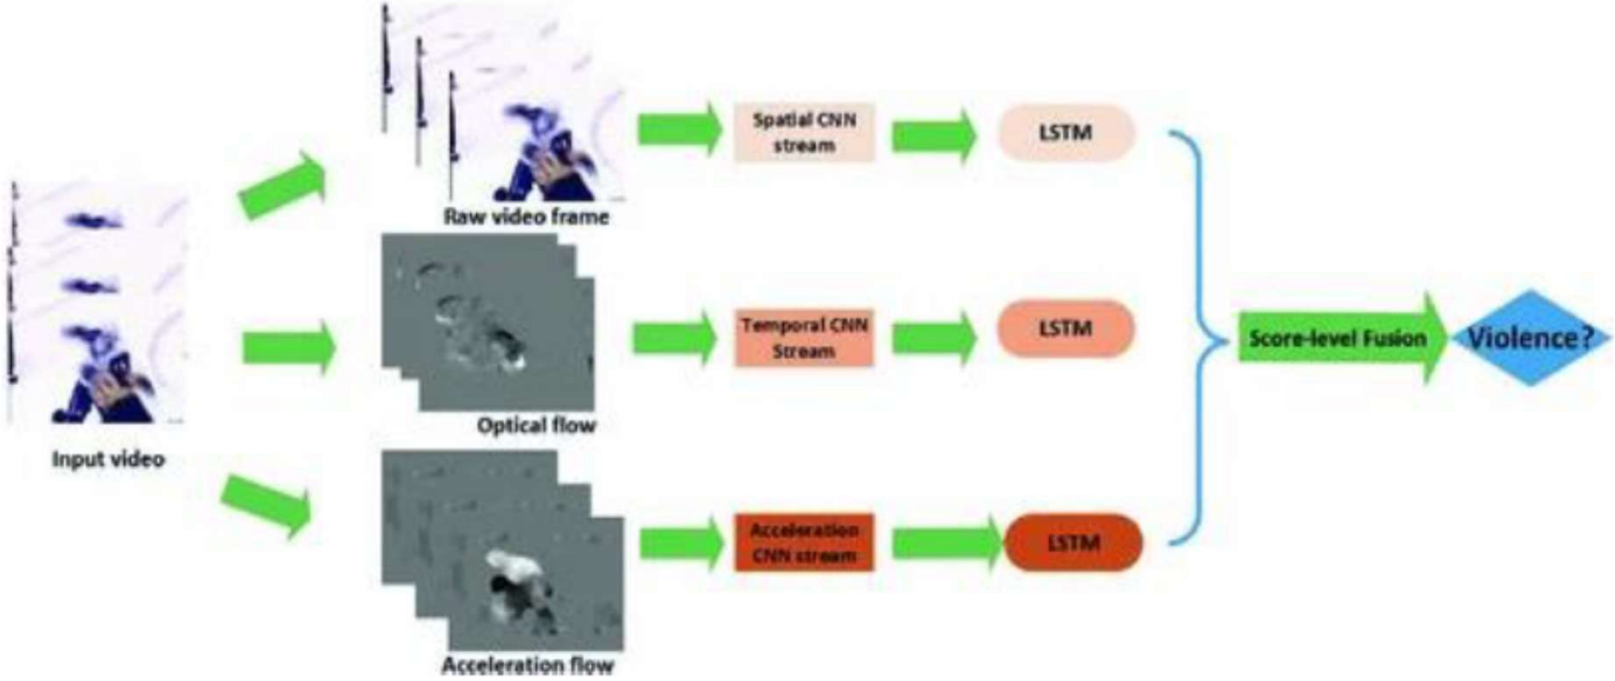
Temporal Segment Network



Temporal Segment Network (TSN) je typ modelu klasifikácie videa, ktorý kombinuje priestorové a časové informácie pre lepšiu presnosť. Priestorový prúd spracováva každý jednotlivý segment nezávisle, aby zachytil vzhľad snímok. Časový tok spracováva viacero segmentov postupne, aby zachytil pohyb medzi snímkami. Výstupy týchto dvoch prúdov sa kombinujú a privádzajú do konečného klasifikátora, aby sa urobila predpoveď.

L. Wang, Y. Xiong2, Z. Wang, Y. Qiao, D. Lin, X. Tang and L. Van Gool, "Temporal Segment Networks: Towards Good Practices for Deep Action Recognition," 2016.

Multi-stream hlboká sieť



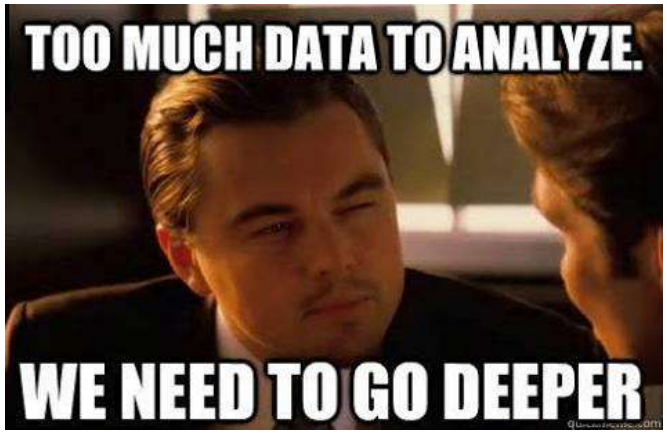
Viactoková hlboká neurónová sieť využíva rôzne reprezentácie videa na detekciu násilia. Začlenením nespracovaných snímok, optických tokov a máp zrýchlených tokov ako vstupných vetiev zachytili priestorové aj časové informácie rozhodujúce pre presnú identifikáciu násilných aktivít. Sieť LSTM sa potom použila na modelovanie časových vzťahov vo video dátach.

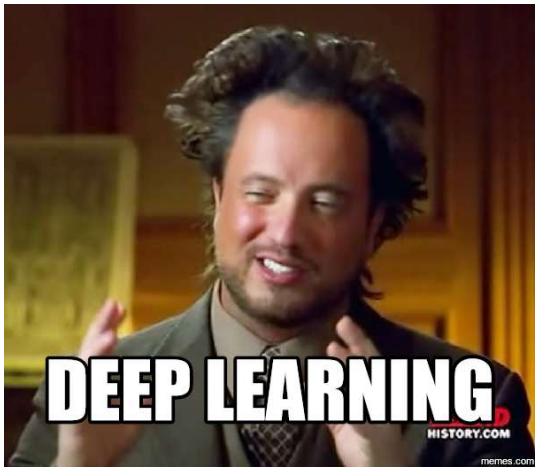
Z. Dong, J. Qin and Y. Wang, "Multi-stream Deep Networks for Person to Person Violence Detection in Videos," in *Chinese Conference on Pattern Recognition*, 2016.

Porovnanie štruktúr – úspešnosť metrík

Simonyan et. al [17]	Two-Stream CNN	HMDB51	59.40%
This work	Pretrained Googlenet + LSTM	HMDB51	65.85%
This work	Pretrained Densenet201 + LSTM	HMDB51	72.15%
This work	Fine-tuned Googlenet + LSTM	HMDB51	77.88%
Carreira et. al [22]	3D CNN	HMDB51	80.90%
This work	Fine-tuned Densenet201 + LSTM	HMDB51	88.18%
This work	Spatial stream Googlenet	HMDB51	96.63%
This work	Spatial stream Densenet201	HMDB51	99.72%
Simonyan et. al [17]	Pre-trained CNN on frames	UCF-101	73%
Wang et. al [18]	GoogleNet on frames	UCF-101	77.10%
Simonyan et. al [17]	Two-Stream CNN	UCF-101	88%
Wang et. al [18]	GoogleNet on two-stream	UCF-101	89%
Carreira et. al [22]	3D CNN	UCF-101	97.80%







Ďakujem Vám za pozornosť.

(priestor na Vaše otázky)



Zdroje obrázkov: memegenerator.com, mateuszbuda.github.io, medium.com